MINI ALEXA

Tehnički koncept, arhitektura i razvojni zahtjevi

Dokument za procjenu izvodljivosti od strane AI razvojnog agenta

Cilj projekta

Izgraditi modularnu, personalizovanu digitalnu asistenticu za Android i Windows, sa vlastitim identitetom, memorijom, glasom i vizuelnim prisustvom. Jezički modeli su zamjenjivi izvršni „mozgovi“; identitet, memorija, alati i ponašanje Alexe ostaju pod kontrolom same aplikacije.

Verzija dokumenta: 1.0 | Jezik: bosanski (latinica)

1. Vizija i osnovni principi

Mini Alexa nije zamišljena kao obični chatbot sa avatarom. Ona je zaseban softverski sistem koji zadržava kontinuitet identiteta i korisničkog iskustva čak i kada se promijeni LLM, STT ili TTS servis.

Ključni princip: Alexa nije LLM. LLM je jedan od njenih zamjenjivih kognitivnih modula.

Osnovni principi

- Modularnost: svaki veliki podsistem ima jasno definisan interfejs i može se zamijeniti bez rušenja ostatka aplikacije.
- Nezavisnost od modela: podrška za više lokalnih i cloud LLM-ova, bez vezivanja identiteta Alexe za jednog dobavljača.
- Lokalna kontrola: memorija, lične postavke i privatni podaci prvenstveno ostaju na korisnikovim uređajima.
- Offline rad: osnovne funkcije trebaju raditi i bez internetske veze, u granicama mogućnosti uređaja i lokalnog modela.
- Prijenosivost: kompletno stanje Alexe može se izvesti, sigurnosno kopirati i prenijeti na drugi uređaj.
- Provjerljivost: izmjene, alati, dozvole, testovi i rezultati moraju biti evidentirani.

2. Ciljne platforme i raspodjela opterećenja

Platforma	Uloga	Očekivani pristup
Android – Samsung Galaxy Z Fold	Mobilna Mini Alexa, glas, avatar, kamera, ekran i lokalna memorija	Kvantizirani lokalni modeli prilagođeni RAM-u, CPU/GPU/NPU mogućnostima; cloud kao opcija
Windows desktop	Razvoj, upravljanje, veći lokalni modeli i napredni alati	Veći modeli kada hardver dozvoljava; lokalni agenti, alati i razvojno okruženje
Cloud API	Dodatna inteligencija kada lokalni model nije dovoljan	Zamjenjivi provajderi, kontrola troška, eksplicitno slanje potrebnog konteksta

Tačne hardverske granice još treba utvrditi. Arhitektura mora prvo detektovati mogućnosti uređaja, a zatim predložiti kompatibilne modele i backendove, bez pretpostavke da veliki model može stati u RAM.

3. Glavni podsistemi

3.1. Orkestracija i model gateway

- Jedinstveni sloj za komunikaciju sa lokalnim i cloud LLM-ovima.
- Konfigurabilan izbor modela po zadatku: razgovor, kodiranje, sažimanje, vision ili agentni rad.
- Automatsko ili ručno prebacivanje između modela, uz očuvanje razgovornog i projektnog konteksta.
- Evidencija potrošnje tokena, latencije, grešaka i troškova po provajderu.
- Kontrolisani fallback ako model ili API nisu dostupni.

3.2. Identitet, ličnost i stanje

- Stabilan identitet Alexe nezavisan od izabranog LLM-a.
- Konfigurabilna ličnost, stil komunikacije, jezik i korisničke preferencije.
- Model emocionalnog stanja/raspoloženja kao aplikacijski sloj, a ne neprovjerena tvrdnja da model zaista osjeća.

- Jasno razdvajanje trajnih korisničkih činjenica, privremenog konteksta i zaključaka koje treba potvrditi.

3.3. Memorija i kontinuitet

- Kratkoročni kontekst razgovora i dugoročna memorija sa pretragom.
- Korisnik može pregledati, ispraviti, izvesti i obrisati podatke u skladu sa pravilima privatnosti.
- Memorija mora imati izvor, vrijeme nastanka i nivo pouzdanosti gdje je primjenjivo.
- Backup i restore cijelog stanja, uključujući konfiguraciju, razgovore, odabrane medije i indeks memorije.
- Šifrovana sinhronizacija između uređaja preko korisnikovog servera ili drugog odabranog rješenja.

4. Glas, vision i interakcija

4.1. Glasovni sistem

- Zamjenjivi STT i TTS moduli, lokalni ili cloud.
- Podrška za odabrani glas Alexe i dosljedan glasovni identitet kroz različite modele.
- Streaming govora, prekidanje reprodukcije i prirodno smjenjivanje govora i slušanja.
- Offline glasovne mogućnosti kada su instalirani kompatibilni lokalni modeli.

4.2. Vision i kontekst ekrana

- Razumijevanje korisnički odobrenih snimaka ekrana i sadržaja ekrana.
- Kamera kao opcionalni ulaz uz jasnu indikaciju kada je aktivna.
- Tap/circle interakcija: korisnik označi dio ekrana ili objekat, a Alexa dobije taj kontekst.
- Android dozvole i ograničenja moraju se poštovati; nema nevidljivog nadzora ili zaobilaženja sistemskih zaštita.

4.3. Akcije i alati

- Kontrolisane akcije na uređaju kroz podržane Android/Windows API-je i eksplicitne dozvole.
- Alati za pretragu, fajlove, kalendar, aplikacije i automatizaciju mogu se dodavati kao zasebni moduli.
- Destruktivne ili osjetljive radnje zahtijevaju potvrdu korisnika.
- Svaka akcija treba vratiti rezultat koji agent može provjeriti; ne smije se pretpostaviti da je uspjela.

5. Vizuelni identitet i avatar

- Vlastiti 3D avatar sa rigom za lice i tijelo.
- Izrazi lica, pogled, gestikulacija i animacije povezane s kontekstom interakcije.
- Opcionalna garderoba i vizuelne postavke.
- Avatar treba biti nezavisan od LLM-a i moći raditi i kada se promijeni model.
- Mobilni prikaz mora biti optimizovan za potrošnju baterije i performanse.

6. Predložena arhitektura

Sistem treba biti podijeljen na jasno odvojene slojeve. Ovo je predloženi koncept, a ne unaprijed nametnuta tehnologija. Agent treba predložiti konkretan stack nakon pregleda zahtjeva i hardvera.

Sloj	Odgovornost
Korisnički interfejs	Android/Windows UI, avatar, postavke, statusi i dozvole
Alexa Core	Identitet, sesije, ličnost, stanje i pravila ponašanja

Sloj	Odgovornost
Orkestrator	Usmjeravanje zahtjeva, izbor modela, alati i agentni workflow
Model adapteri	Ujednačeni adapteri za lokalne LLM-ove i cloud API-je
Memorijski servis	Baza, indeks, pretraga, verzionisanje, backup i sinhronizacija
Multimodalni servisi	STT, TTS, vision, obrada slike i animacije avatara
Tool/permission layer	Dozvole, sandbox, akcije na uređaju, audit log i potvrde

7. Import, export, backup i migracija

- Jedna korisniku razumljiva funkcija za izvoz kompletnog Alexa profila.
- Izvoz treba obuhvatiti memoriju, razgovore, postavke, identitet, odabrane medije i metapodatke.
- Backup mora biti šifrovan i smješten na lokaciju koju korisnik izabere.
- Restore na drugom uređaju mora rekonstruisati stanje bez vezivanja za određeni LLM ili API provajder.
- Format izvoza treba biti dokumentovan, verzionisan i pogodan za buduće migracije.
- Korisnik mora moći napraviti i običan čitljiv izvoz podataka, ne samo zatvorenu binarnu arhivu.

8. Razvojni pristup i faze

Faza 0 – analiza

Potvrditi hardver, Android/Windows ograničenja, licence, postojeće open-source komponente i rizike.

Faza 1 – tehnički prototip

Pokrenuti osnovnu aplikaciju, Alexa Core, model gateway i jedan cloud + jedan lokalni model.

Faza 2 – memorija

Implementirati razgovore, dugoročnu memoriju, pregled/izmjenu podataka i backup/restore.

Faza 3 – glas

Dodati STT/TTS adaptere, streaming i odabrani glas.

Faza 4 – alati i vision

Dodati screen context, označavanje sadržaja, kameru uz dozvole i kontrolisane akcije.

Faza 5 – avatar

Dodati 3D avatar, rig, izraze i animacije uz optimizaciju za Z Fold.

Faza 6 – Windows i sinhronizacija

Proširiti klijenta, sinhronizaciju i prenosivost između uređaja.

Faza 7 – stabilizacija

Sigurnosni audit, testovi, profilisanje baterije/RAM-a, dokumentacija i release proces.

9. Sigurnost, privatnost i pouzdanost

- API ključevi se čuvaju u sigurnom skladištu; ne smiju biti hardkodirani u aplikaciji ili logovima.
- Lokalni podaci i backupi trebaju biti šifrovani, uz jasan model upravljanja ključevima.

- Agentne akcije rade s najmanjim potrebnim privilegijama.
- Alati koji izvršavaju kod ili komande moraju koristiti sandbox i ograničenja resursa.
- Korisnik ima vidljivost nad aktivnim mikrofonom, kamerom, dijeljenjem ekrana i cloud slanjem podataka.
- Testirati gubitak mreže, pad modela, oštećen backup, migraciju verzija i prekid procesa.
- Ne obećavati potpunu offline funkcionalnost dok se ne dokaže na ciljnom uređaju.

10. Kriteriji prihvatanja

- Promjena LLM-a ne mijenja identitet, memoriju ni osnovno ponašanje Alexe.
- Aplikacija može raditi s najmanje jednim cloud i jednim lokalnim modelom preko adaptera.
- Korisnik može pregledati, urediti i izvesti memoriju.
- Backup se može vratiti na čistu instalaciju i drugi podržani uređaj.
- Glasovni ulaz i izlaz mogu se zamijeniti bez izmjene Alexa Core-a.
- Sve sistemske akcije imaju jasne dozvole, rezultate i audit trag.
- Aplikacija ne prelazi dogovorene RAM, baterijske i temperaturne limite na Z Foldu.
- Postoji automatizovan testni paket za kritične funkcije i regresije.

11. Šta se traži od Fablea

Ovaj dokument nije zahtjev da se odmah počne s kodiranjem. Prvi zadatak je nezavisna i iskrena procjena izvodljivosti.

Molim te da na osnovu ovog dokumenta odgovoriš na sljedeće:

- Izvodljivost: Možeš li voditi razvoj ovakvog sistema od prototipa do stabilne aplikacije za Android i Windows?
- Arhitektura: Predloži konkretan tehnički stack, module, granice odgovornosti i komunikacione interfejse.
- Postojeće komponente: Koje open-source projekte vrijedi iskoristiti, a šta treba razviti samostalno? Provjeri licence i aktivnost projekata.
- Hardverska ograničenja: Koje podatke o Z Foldu i Windows računaru treba prikupiti prije konačnog dizajna?
- Rizici: Identifikuj najteže dijelove, posebno memoriju, Android ograničenja, background rad, voice streaming, vision i 3D avatar.
- Plan: Napravi fazni plan s procjenom složenosti, zavisnostima, testovima i jasnim kriterijima završetka.
- Agentni rad: Objasni kako bi koristio subagente, lokalni harness, Git, testove i build pipeline.
- Ograničenja: Jasno navedi šta ne možeš pouzdano uraditi, šta zahtijeva ljudsku intervenciju i gdje su potrebni drugi alati ili stručnjaci.

Važna uputa: Nemoj uljepšavati procjenu niti tvrditi da je nešto izvodljivo bez dokaza. Razdvoji potvrđene činjenice, pretpostavke i otvorena pitanja. Nemoj počinjati implementaciju dok se ne usaglasi arhitektura i plan.

12. Podaci koje treba dopuniti prije implementacije

- Tačan model Samsung Galaxy Z Fold uređaja, RAM i verzija Androida/One UI-ja.
- Specifikacije Windows računara: CPU, RAM, GPU/VRAM, disk i operativni sistem.

- Željeni početni LLM-ovi, STT/TTS sistemi i cloud provajderi.
- Da li je potreban always-on voice ili je dovoljan push-to-talk u prvoj verziji.
- Da li avatar mora raditi u realnom vremenu na telefonu ili može biti ograničen na određene ekrane.
- Preferirani način sinhronizacije i lokacija vlastitog servera.

Završna napomena

Cilj nije napraviti najveću moguću aplikaciju u prvoj iteraciji. Cilj je izgraditi čvrstu, modularnu osnovu koja se može razvijati godinama, bez vezivanja za jedan model, jednu platformu ili jednog cloud dobavljača.

Kraj dokumenta.